

Information, Calcul et Communication

Module 3 : Systèmes

Leçon III.2 : Stockage et transmission de l'information

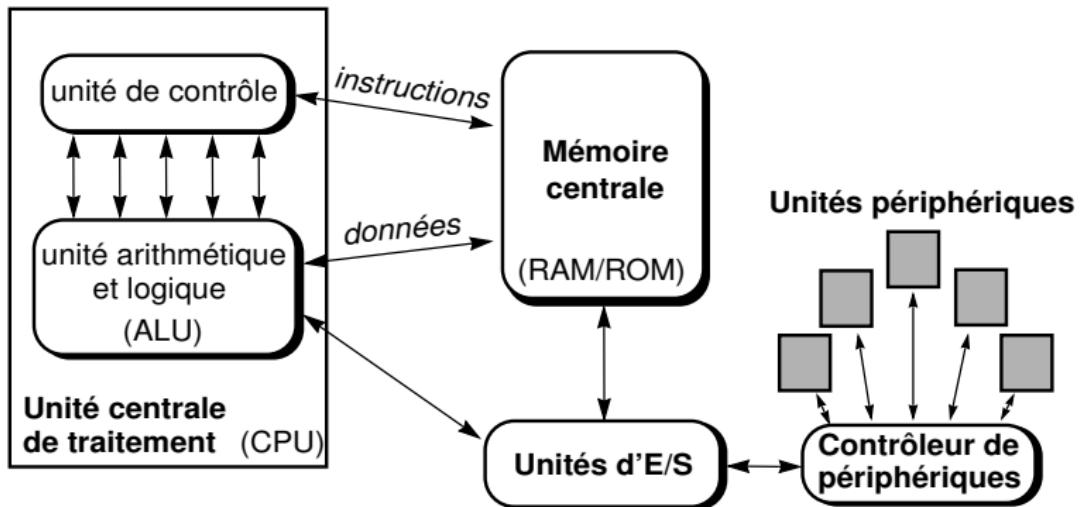
préparée par Prs. Ph. Janson, W. Zwaenepoel
& A. Ailamaki

Objectifs du cours d'aujourd'hui

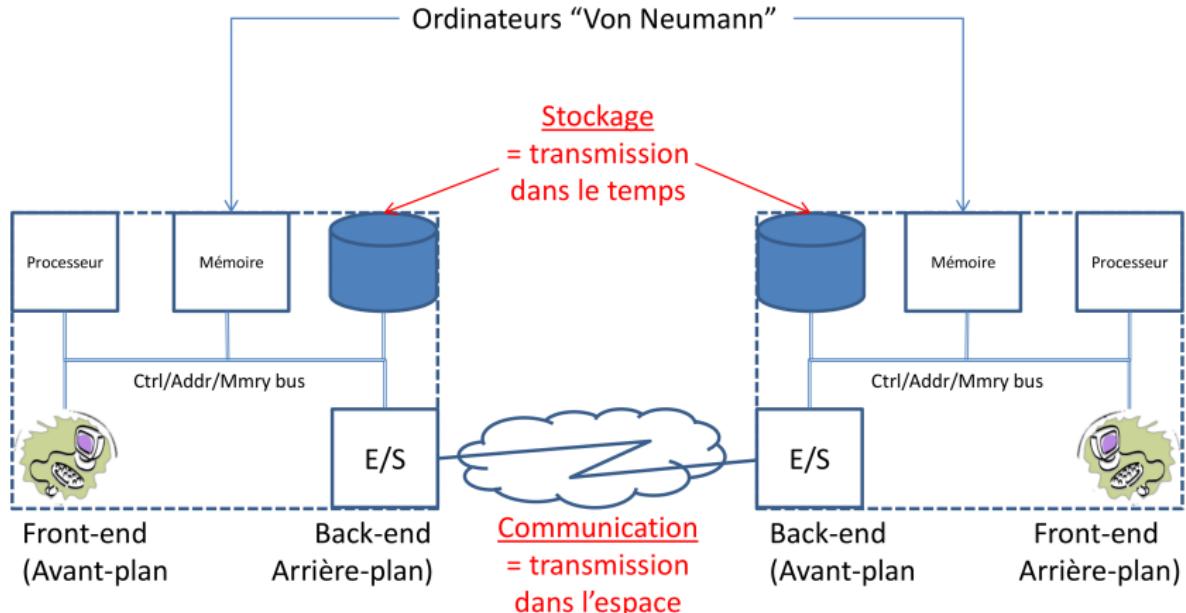
Après quelques notions sur l'architecture des ordinateurs « de Von Neumann », cette deuxième leçon porte sur :

- ▶ la structure des mémoires de masse (mémoires de stockage, mémoires rémanentes)
- ▶ la structure des communications réseau

Architecture de Von Neumann (1955)



Stockage et communication des données



But de cette leçon

Répondre à une seule et même question dans deux cas :

- ▶ Dans le cas du stockage :

Où et comment **stocker** des données de façon à pouvoir les **retrouver plus tard** ?

- ▶ Dans le cas des réseaux :

Quand et comment **envoyer** des données de façon à pouvoir les **recevoir à distance** ?

- ▶ stockage : communication dans le temps au moyen de l'espace
- ▶ télécommunication (réseaux) : communication dans l'espace en utilisant du temps

Plan

- ▶ Le **besoin de structure** dans les données
- ▶ Stockage :
 - ▶ **Types de structures** de stockage : séquentielles, hiérarchiques, relationnelles, ...
 - ▶ **Identification, localisation, et accès** à des données stockées
- ▶ Réseaux :
 - ▶ **Types de structures** de transmission : couches et encapsulation de protocoles
 - ▶ **Identification, localisation, et accès** à des données en réseau

Le stockage : pourquoi ?

- ▶ La mémoire centrale est
 - ▶ Trop petite (quelque Go)
 - ▶ Volatile (tout est perdu quand on éteint)
 - ▶ Trop chère
- ▶ Le stockage est donc nécessaire
 - ▶ pour retenir *toutes* les données
 - ▶ à long terme
 - ▶ et à coût honorable

☞ **Où et comment** stocker des données de façon à les **retrouver** ?

Au départ du problème : contraintes technologiques

Contraintes technologiques

	Latence	Débit	Coût (\$/Go)	Capacité	Rétention	Accès
RAM	1 - 100 ns	Go/s	10	Mo - Go	NON	Aléatoire
Flash	μ s	Go/s	0.5	Go - To	Oui	Aléatoire
Disques	ms	100s Mo/s	0.05	> To	Oui	<u>Aléatoire avec délai</u>
Bandes magnétiques	Encore plus lent !	100s Mo/s	Encore moins cher !	Encore plus grand !	Oui	Séquentiel

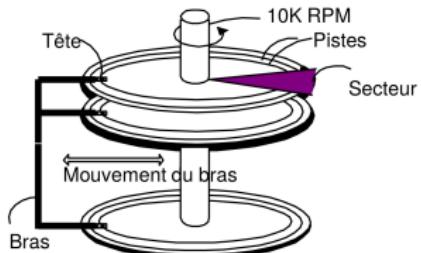
Flash

Accès aléatoire comme RAM mais par pages comme HDD



HDD

Latence de rotation + positionnement du bras

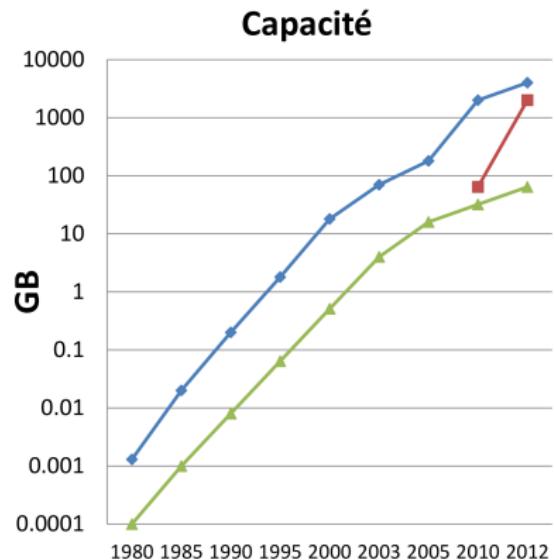
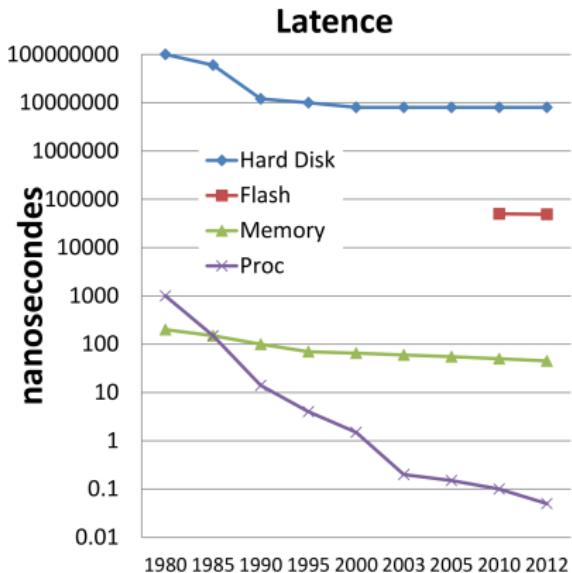


Bandes

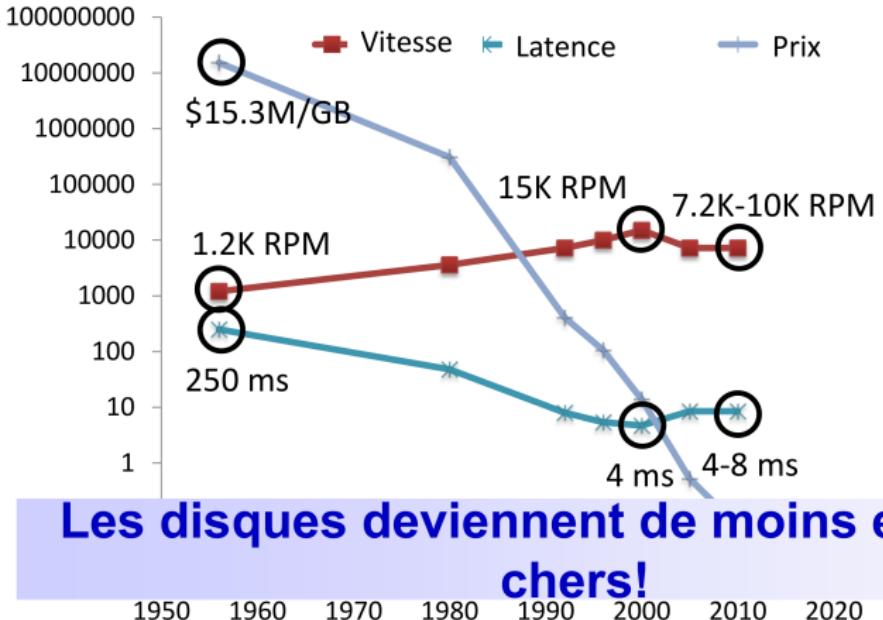
Accès strictement séquentiel
=> latence de déroulement



Contraintes technologiques



Contraintes technologiques



Les disques deviennent de moins en moins chers!

MAIS pas plus rapides!

Le besoin de structure dans le stockage de données

Imaginons un disque (ou autre support) sans aucune structure :



Comment y retrouver une information qu'on cherche ?

- 👉 Même la «recherche non structurée» (e.g. Google) a besoin de structure (à elle, qu'elle crée) pour retrouver ce qu'on lui demande !

Le besoin de structure dans la transmission de données

- ▶ Imaginons un signal arrivant d'un réseau, sans aucune structure



- ▶ Comment savoir si c'est un signal ou juste du bruit ?
 - ▶ Comment savoir où il commence et où il finit ?
 - ▶ Comment savoir d'où il vient ?
 - ▶ Comment interpréter ce qu'il contient ?

Le besoin de structure dans le stockage de données (1/2)

Données non-structurées
(= désordonnées, sans aucun ordre particulier)

- ▶ Facile à gérer, stocker, transporter
- ▶ Plus difficile à exploiter, explorer, interpréter

Exemple : dans l'océan de données non-structurées que Google tente d'indexer sur la toile, retrouver des informations sur le *professeur de Statistiques Michael Jordan* est un défi.



Le besoin de structure dans le stockage de données (2/2)

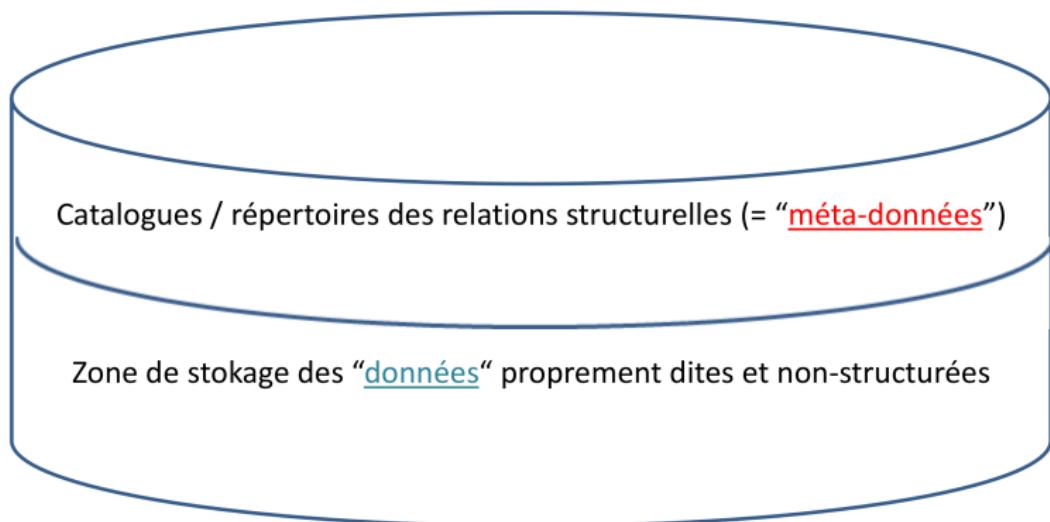
Données structurées
(= ordonnées en listes, piles, hiérarchies, tables, etc.)

- ▶ Facile à exploiter, explorer, interpréter
- ▶ Plus difficile à gérer, stocker, transporter

Exemple : retrouver des informations sur le *professeur Michael Jordan* dans les bases de données de son université est trivial.



Principe de base de la structuration des données stockées



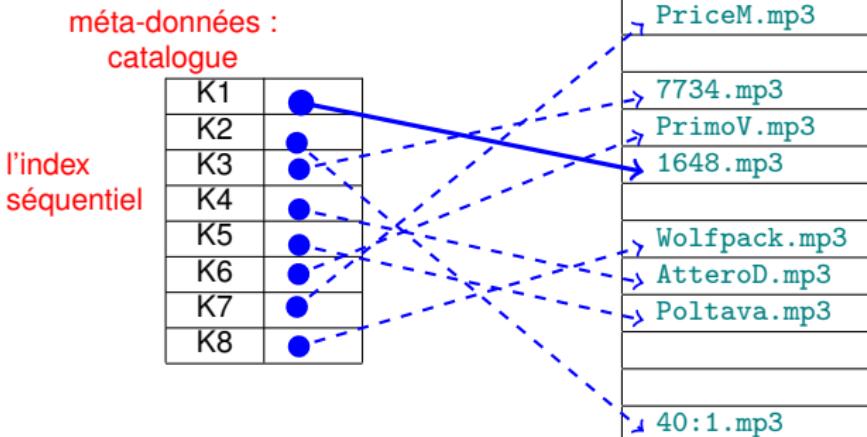
Le catalogue d'une médiathèque

Catalogue :

indiqué (= structuré) par ordre alphabétique (par exemple des titres)

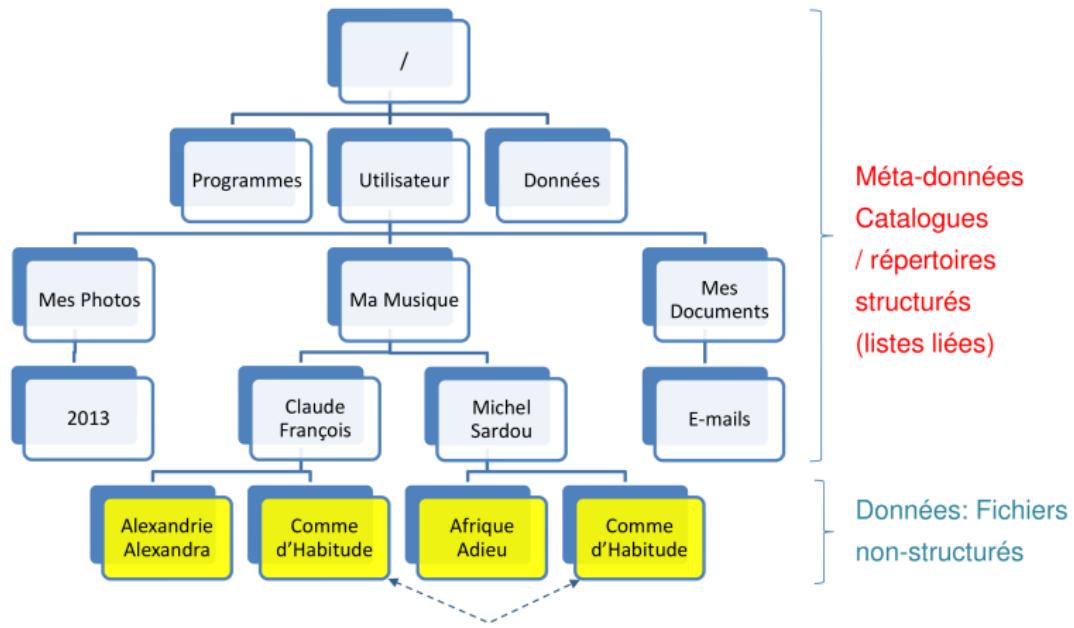
Médiathèque :

rangée par ordre d'acquisition
rangée selon la place disponible



- Mais il est difficile de retrouver dans cette médiathèque toutes les œuvres d'un interprète

Une médiathèque hiérarchique



- Mais il est difficile de retrouver dans cette médiathèque tous les interprètes d'une œuvre donnée

Une mediathèque relationnelle

Méta-données = Catalogues / répertoires tabulaires

Titre	Xaut	Xint	MP3	Index	Interprètes	Index	Auteurs
Afrique Adieu	5	7		1		1	
Alexandrie Alexandra	2	3		2		2	C. François
Comme d'Habitude	2	3		3	C. François	3	
Comme d'Habitude	2	7		4		4	
				5		5	M. Sardou
				6		6	
				7	M. Sardou	7	
				8		8	
				9		9	

► Mais il est moins direct de trouver si un auteur est aussi interprète ou vice versa

Données = fichiers

Accès à l'information

Le but de toutes ces métadonnées est de permettre l'accès à l'information :

- ▶ **l'identifier** :
 - ▶ comprendre les besoins, les requêtes possibles, ...
 - ▶ l'information elle-même (quelle est elle ? ↗ besoins spécifiques)
- ▶ **retrouver** l'information identifiée :
 - ▶ la **localiser**
 - ▶ y **accéder**

Identification, localisation, et accès à des données stockées

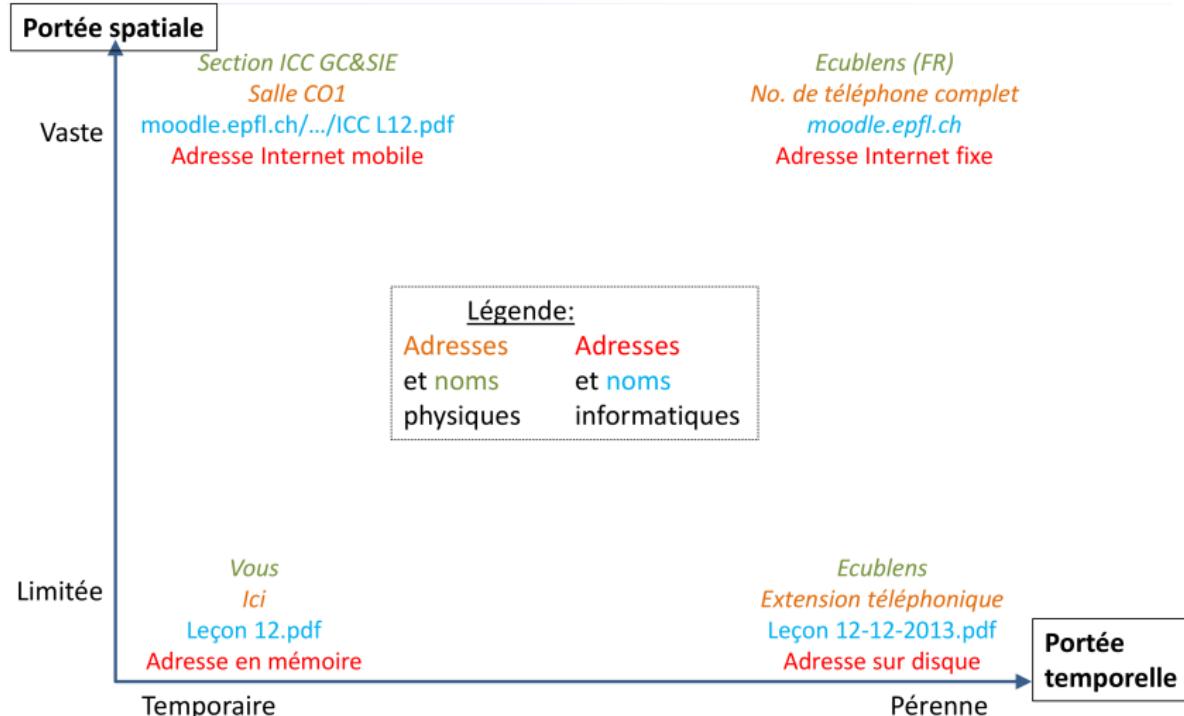
- ▶ Structurée ou non, une information n'a de sens que dans son contexte spatio-temporel

Paris ne signifie pas la même chose à Troie (France) en 2013 qu'à Troie (Turquie) en 1250 avant J.C.
- ▶ Pour *identifier*/distinguer une information parmi d'autres, il faut lui donner un nom/**identificateur**
Un répertoire/catalogue est alors nécessaire pour *localiser* cette information
- ▶ La localisation de cette information est dénotée par son **adresse** (une place qui lui a été attribuée)
Un mécanisme d'acheminement est alors nécessaire pour *accéder* à cette adresse
- ▶ Pour accéder à cette adresse il faut déterminer une **route** jusqu'à là

Exemples

Identification	Localisation	Accès
▪ EPFL	▪ Route Cantonale, Ecublens	▪ Plan, carte, GPS
▪ Nom, prénom	▪ No. de téléphone	▪ (Anciennement: no. de tél.) Actuellement route tabulée
▪ No. de compte en banque	▪ No. de compte IBAN	▪ Code BIC / SWIFT
▪ Nom d'utilisateur ▪ Adresse e-mail	▪ Adresse e-mail ▪ Adresse Internet du serveur	▪ Adresse Internet du serveur ▪ Route Internet vers le serveur
▪ Nom d'une variable ▪ Nom d'un fichier	▪ Adresse de la variable ▪ Adresse du fichier	▪ Logique d'accès à la mémoire primaire ▪ Logique d'accès Au stockage sur disque

Portée spatio-temporelle des noms et adresses



Résolution des noms et adresses

Vu le nombre de façons de faire référence à des informations :

- ▶ Noms ou adresses
- ▶ Universels ou locaux
- ▶ Permanents ou temporaires

les ordinateurs doivent régulièrement traduire une forme en une autre.

☞ C'est un des rôles essentiels des *logiciels systèmes* :

- ▶ Les compilateurs traduisent ainsi les noms de variables en adresses mémoire
- ▶ Les systèmes de fichiers et les bases de données gèrent le mouvement des données entre mémoire primaire et secondaire y compris la traduction de noms et adresses « secondaires » (universels et permanents) en équivalents « primaires » (locaux et temporaires)

Exemple : compilation de noms de variables en adresses

Identification par nom

- E.g. nom, prénom
- Programme source
 $\text{delta} \leftarrow b^2 - 4*a*c$

a	@a
b	@b
c	@c
(x)	@x
delta	@delta

Table des symboles du compilateur

Localisation par adresse

- No. de téléphone
- Programme objet
- charge R,@c
- mult R,@a
- décale R,2
- écris R,@x
- charge R,@b
- mult R,@b
- diff R,@x
- écris R,@delta

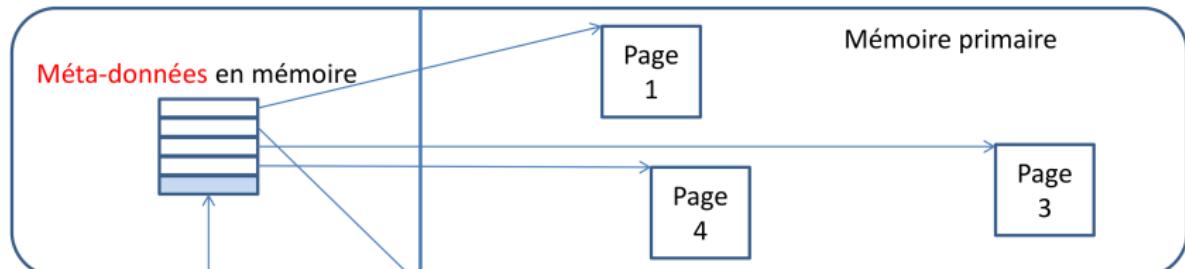
Logique d'adressage de la mémoire

a
b
c
x
delta

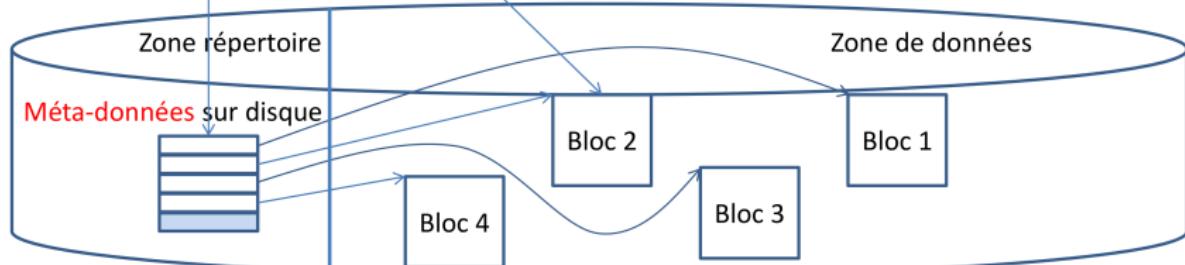
Accès

- Routage de l'appel
Mémoire primaire

Exemple : gestion de noms et adresses primaires et secondaires



Blocs et pages sont **différents de taille mais fonctionnellement équivalents** aux blocs de mémoire de la leçon III.2



Notion de protocole de communication

Protocole : jeu de règles qui gouverne une communication

Toute communication est gouvernée par un protocole
y compris, la communication entre êtres humains

- ▶ en cours
- ▶ au téléphone
- ▶ ...

Un protocole entre êtres humains peut être vaguement défini (quoique...)

Un protocole entre ordinateurs doit être fixé dans tous les détails

Notion de protocole de communication : exemples

- ▶ Où commence et où finit une communication ?
délimitée par deux silences
- ▶ D'où vient-elle et à qui s'adresse-t-elle ?
de l'orateur au public
- ▶ Dans quel langue est-elle exprimée ?
un langage commun aux interlocuteurs
- ▶ Que faire si la communication est perturbée ?
demande de répétition : « *Pardon ?* »
- ▶ A qui le tour de communiquer ?
à chacun son tour

Structuration par couches (abstraction des protocoles)

- Chaque couche gère et abstrait les phénomènes de son niveau pour affranchir les autres couches de ces détails

Exemple d'une conversation téléphonique :

Application		La conversation entre interlocuteurs	
Transport		La connexion électronique entre Natels	
Réseau		Le routage entre antennes via commutateurs	
Lien		La connexion entre votre Natel et sa station GSM	
Physique		La conversion audio-tactile entre vous et votre Natel	

Les couches de l'Internet

5. Application	Terminal interactif ex. SSH	Transfert de fichiers ex. FTP	Courrier électronique SMTP	Naviguer sur la toile HTTP	Le botin Internet DNS	Etc.	
4. Transport	TCP		SSL / TLS		UDP		
3. Réseau	IP (adressage et routage)						
2. Lien	CSMA / CD			PPP	Trunk lines		
1. Physique	Wi-Fi	Ethernet	CATV	ADSL	Trunk lines		

DNS – le bottin de l'Internet, protocole de résolution de noms en adresses

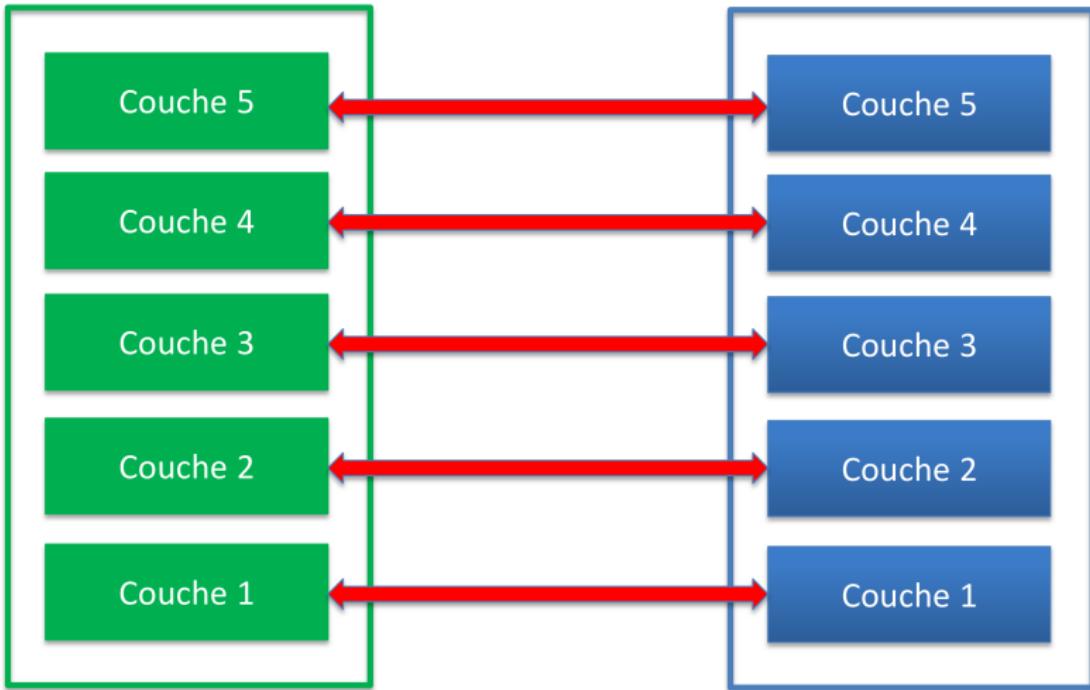
SSH – protocoles de terminaux à distance

FTP, NFS – protocoles de transfert de fichiers

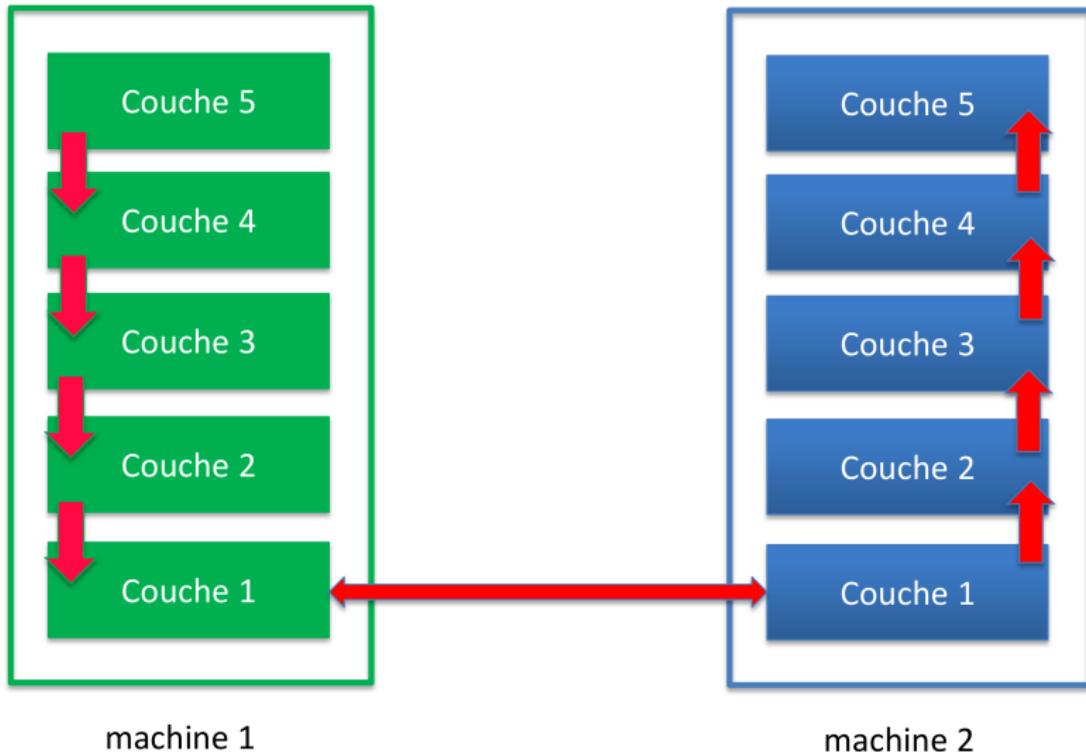
SMTP, POP, IMAP – protocoles de courrier électronique

HTTP – LE protocole de la toile (web, Facebook, Twitter, Google, etc.)

Couches : communication aux niveaux « logiques »



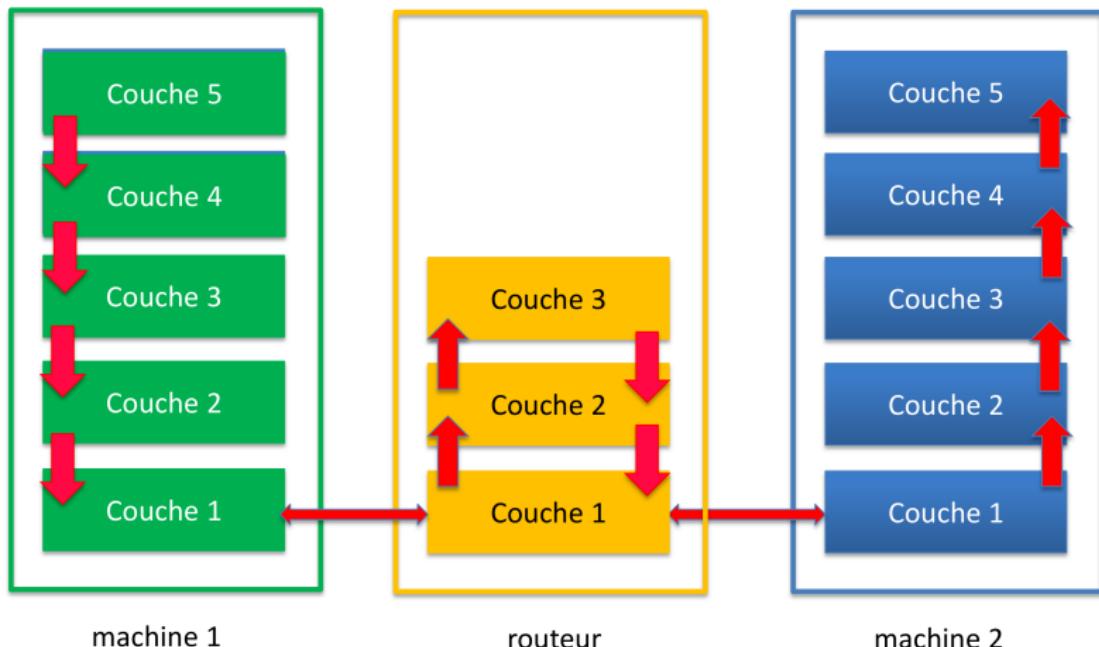
Couches : communication physique simple



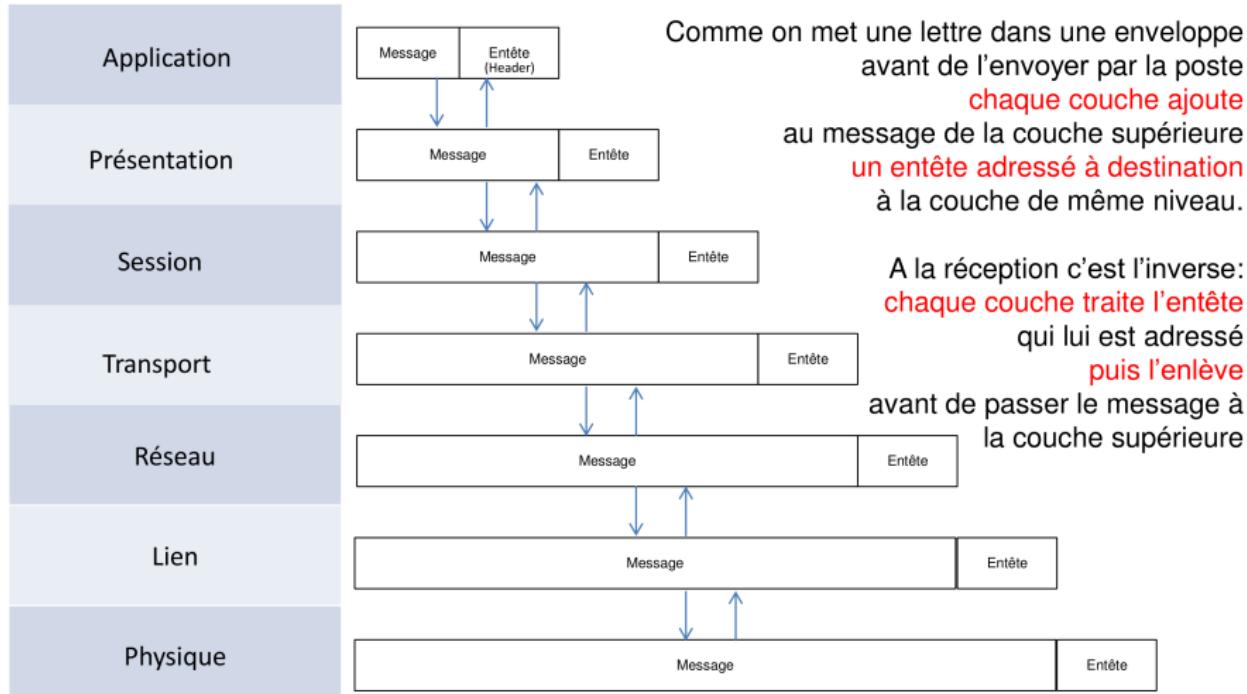
machine 1

machine 2

Couches : communication physique avec relais



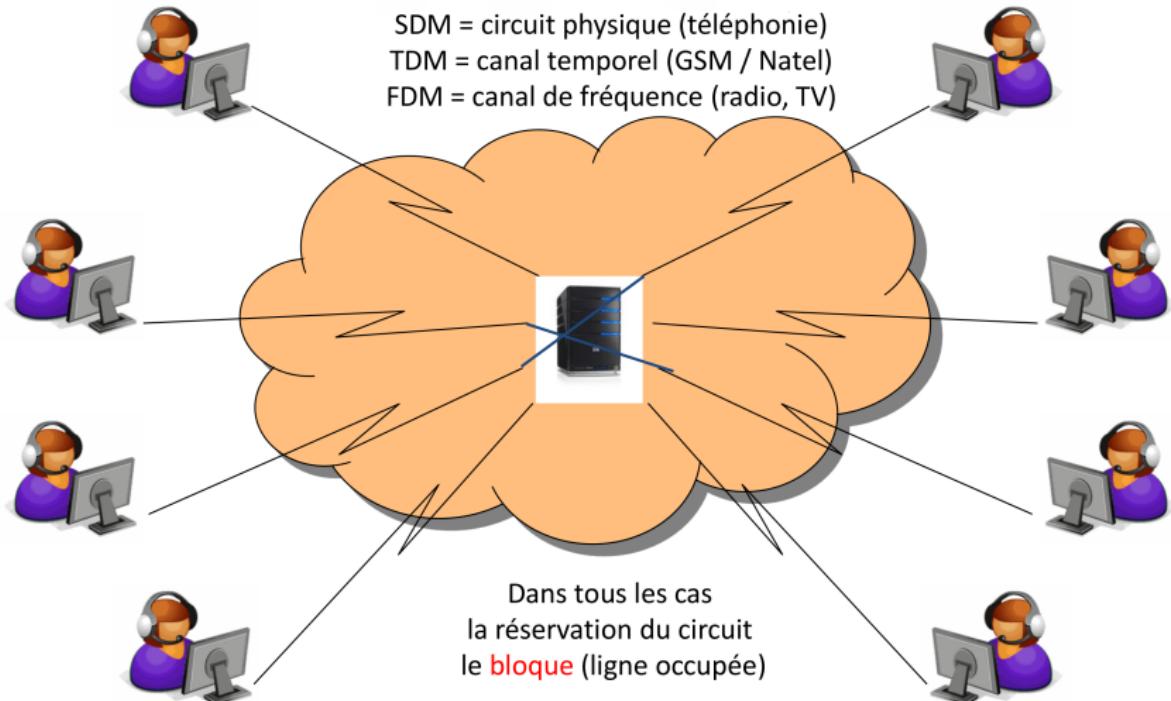
La notion d'encapsulation



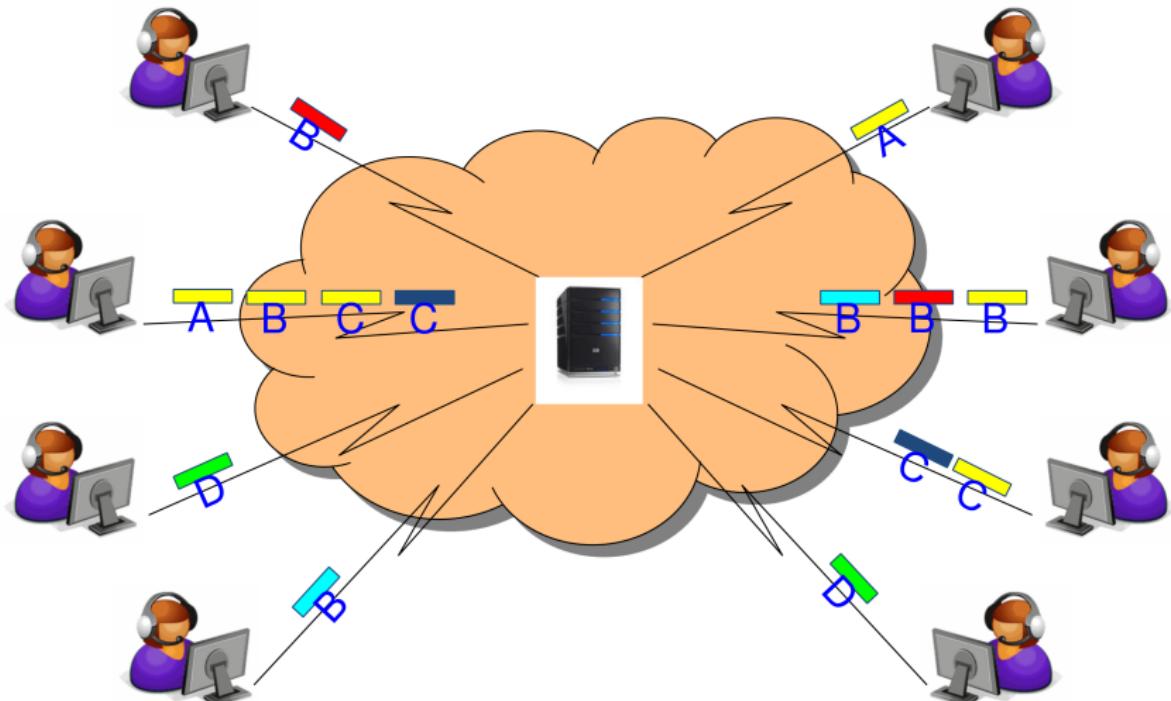
Opérations d'un protocole

- ▶ A la *transmission* d'un paquet : le protocole
 - ▶ reçoit des données
 - ▶ ajoute un entête
 - ▶ envoie le paquet
- ▶ A la *réception* d'un paquet : le protocole
 - ▶ reçoit le paquet
 - ▶ supprime l'entête (en le vérifiant)
 - ▶ passe les données

Couche 3 – Routage téléphonique par commutation de circuits



Couche 3 – Routage Internet par commutation de paquets



Envoi d'un fichier par paquets

fichier (+ entêtes couches supérieures)



paquet 3 paquet 2 paquet 1 paquet 0



Commutation de paquets

Note :

- ▶ des paquets peuvent être perdus en route
- ▶ des paquets peuvent arriver en désordre

Fonctionnalités :

- ▶ envoyer des paquets
- ▶ savoir s'ils sont arrivés :
le destinataire envoie un paquet d'acquittement
- ▶ pouvoir les remettre dans l'ordre
(et ne pas traiter 2 fois le même paquet)



Commutation de paquets

type	seq	données
------	-----	---------

- ▶ type : données ou « paquet d'acquittement »
- ▶ seq : 0,1,2,... identifiant de paquet

Si l'expéditeur ne reçoit pas son paquet d'acquittement au bout d'un certain temps

- ▶ il retransmet
- ▶ un certain nombre de fois puis abandonne

« seq. » permet au récepteur de remettre les paquets dans l'ordre et de savoir si ce sont des retransmissions ou non

« type », « seq. » sont un exemple de **meta-données**

On appelle ces métadonnées (y compris d'autres : taille, source, destinataire, code correcteur d'erreurs, ...) l'**« entête »** du paquet

Couche 3 : adressage IP (Internet Protocol)

IPv4 : 32 bits ↗ ne peuvent adresser que 2^{32} ($\simeq 4 \cdot 10^9$) systèmes écrits a.b.c.d (4 fois 8 bits, en décimal) ; Exemple : [192.168.1.1](#) interprétés comme R.A
= un abonné A (24–8 bits) sur un réseau R (8–24 bits)

IPv6 : 128 bits ↗ peuvent adresser $\simeq 2 \cdot 10^{38}$ systèmes écrits XXXX:XXXX:XXXX:XXXX:XXXX:XXXX:XXXX:XXXX (par 8 groupes de 16 bits, en hexadécimal)
Exemple : [2001:db8:0:85a3:0:0:ac1f:8001](#)

Couche 3 : routage IP (1/2)

Contrairement aux réseaux téléphoniques : **décentralisation totale**, aucune autorité

Les nœuds de commutation n'ont *aucune notion* ni connaissance de connexions

Le routage se fait par « ouï-dire » mais résulte en un calcul distribué de « plus courts chemins » :

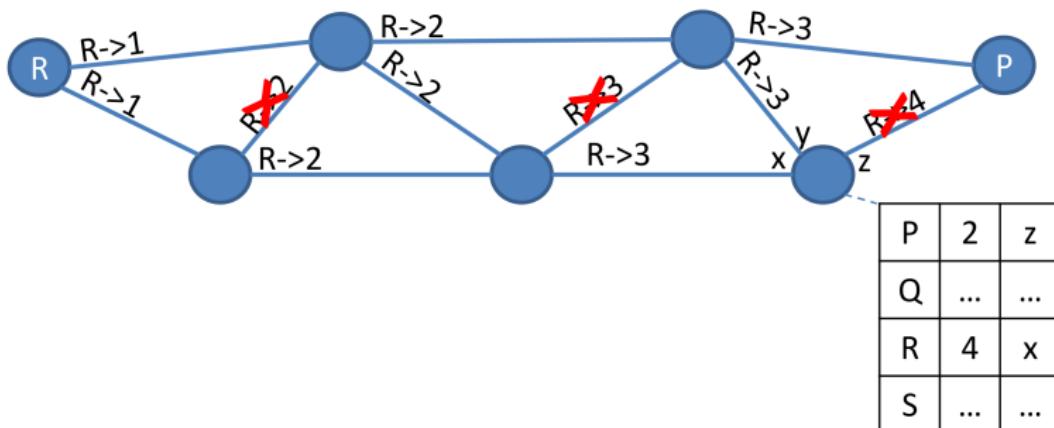
- ▶ chaque nœud annonce à ses voisins la « longueur » des chemins vers les adresses qu'il connaît
- ▶ chaque nœud retient et propage le chemin le plus court parmi ceux annoncés par ses voisins

(cf transp. suivant)

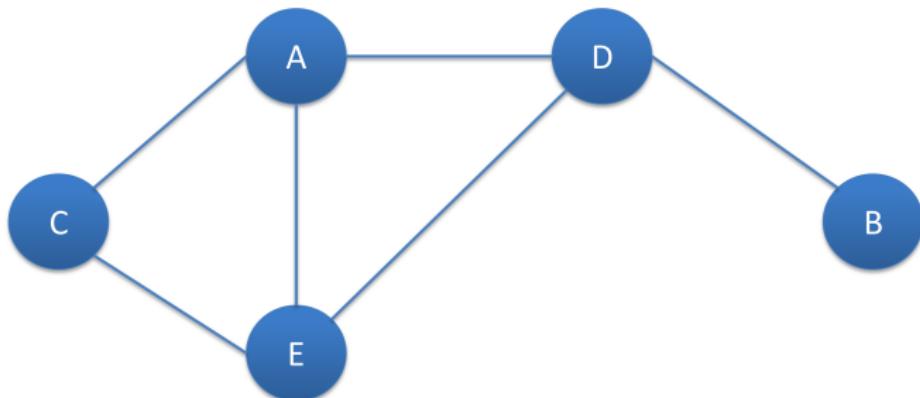
Couche 3 : routage IP (2/2)

Le routage se fait par un calcul distribué de « plus courts chemins » :

- ▶ chaque nœud annonce à ses voisins la « longueur » des chemins vers les adresses qu'il connaît
- ▶ chaque nœud retient et propage le chemin le plus court parmi ceux annoncés par ses voisins

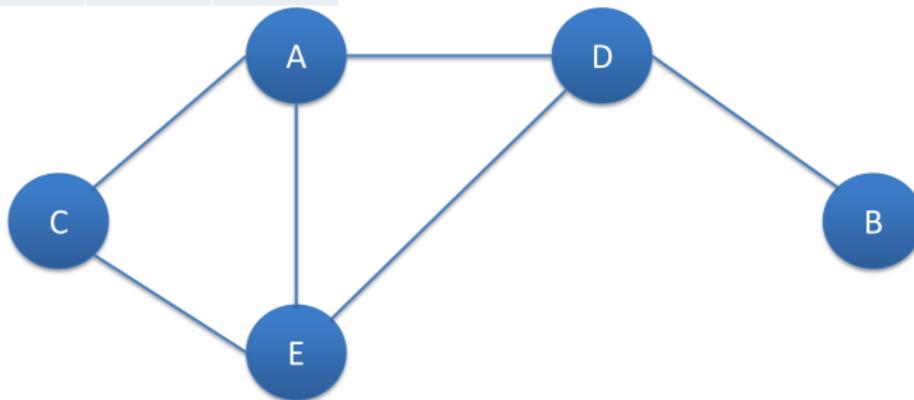


routage IP : exemple



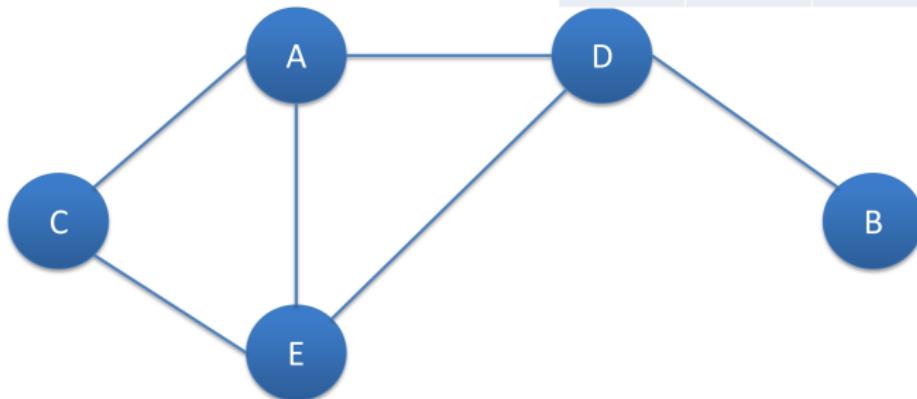
Exemple de table de routage IP (A)

dest	chemin	distance
B	D	2
C	C	1
D	D	1
E	E	1



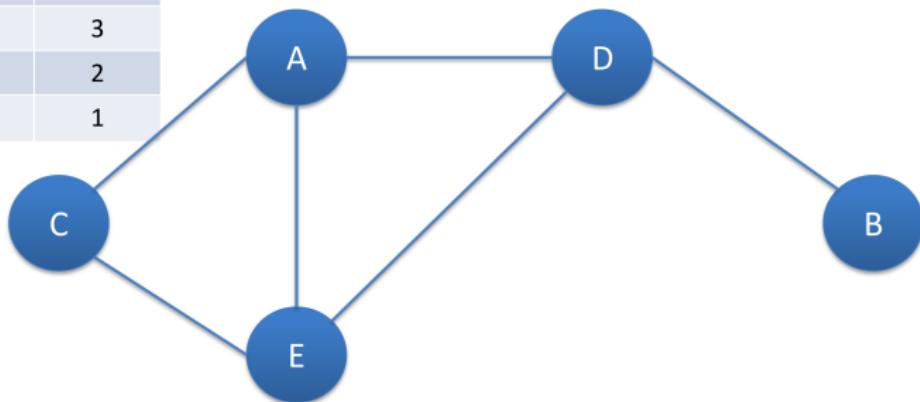
Exemple de table de routage IP (D)

dest	chemin	distance
A	A	1
B	B	1
C	A/E	2
E	E	1



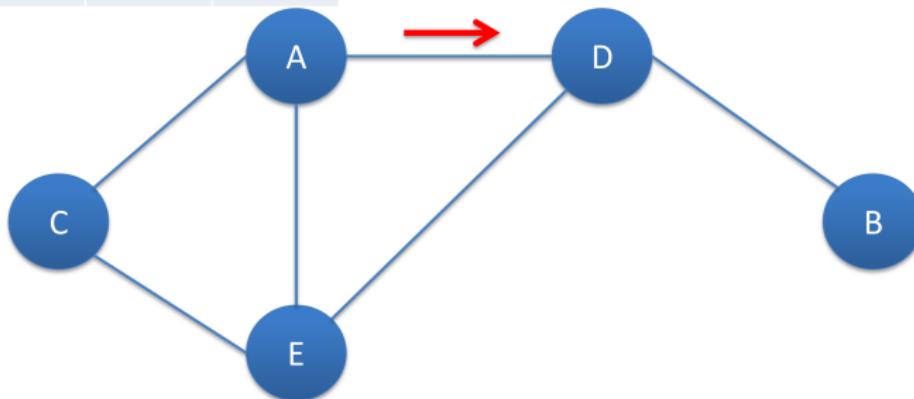
Exemple de table de routage IP (C)

dest	chemin	distance
A	A	1
B	A/E	3
D	A/E	2
E	E	1

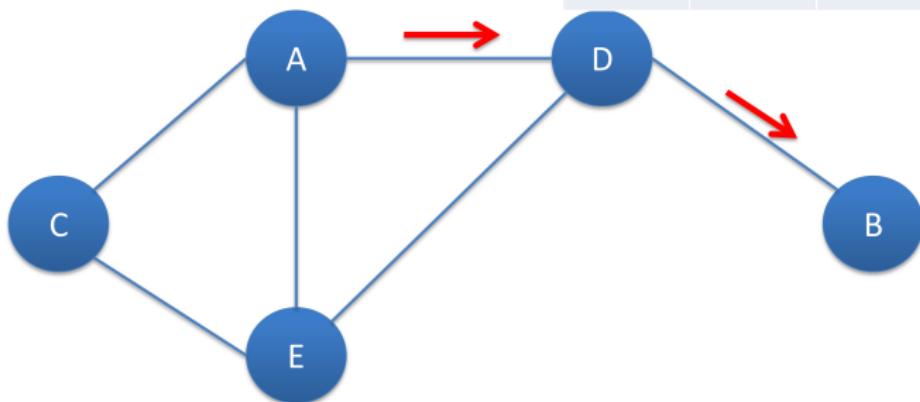


Routage IP de A à B (1/2)

dest	chemin	distance
B	D	2
C	C	1
D	D	1
E	E	1

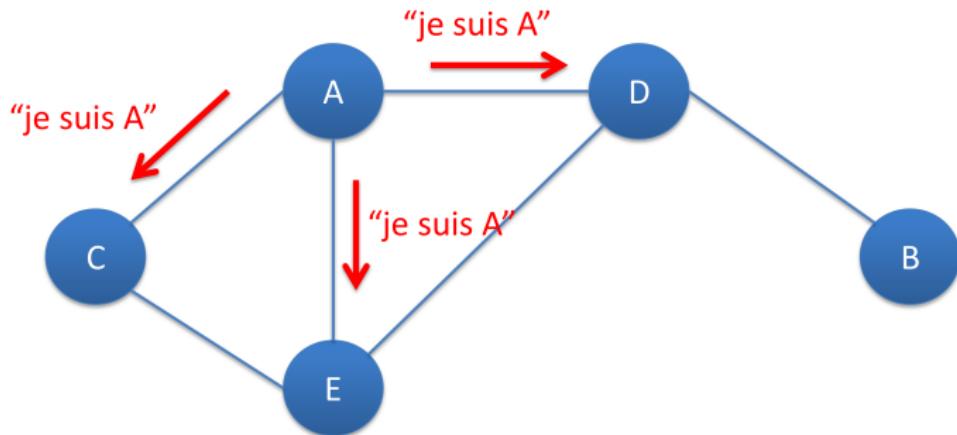


Routage IP de A à B (2/2)

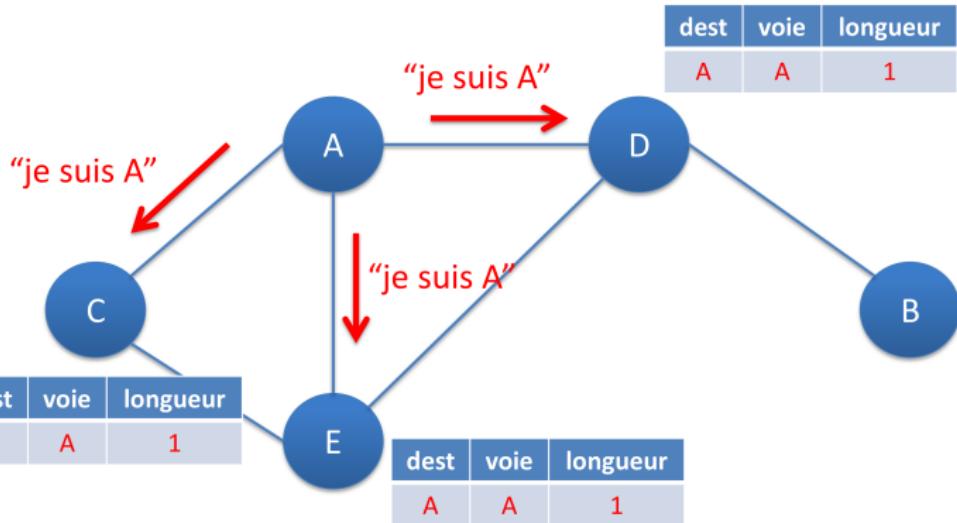


dest	voie	longeur
A	A	1
B	B	1
C	A/E	2
E	E	1

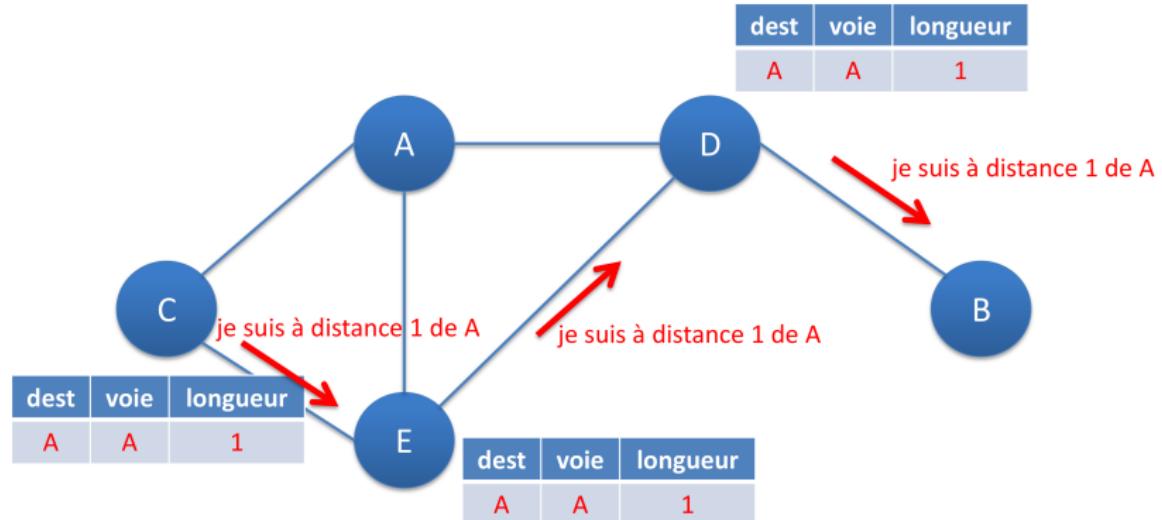
Exemple de calcul de table de routage (1/4)



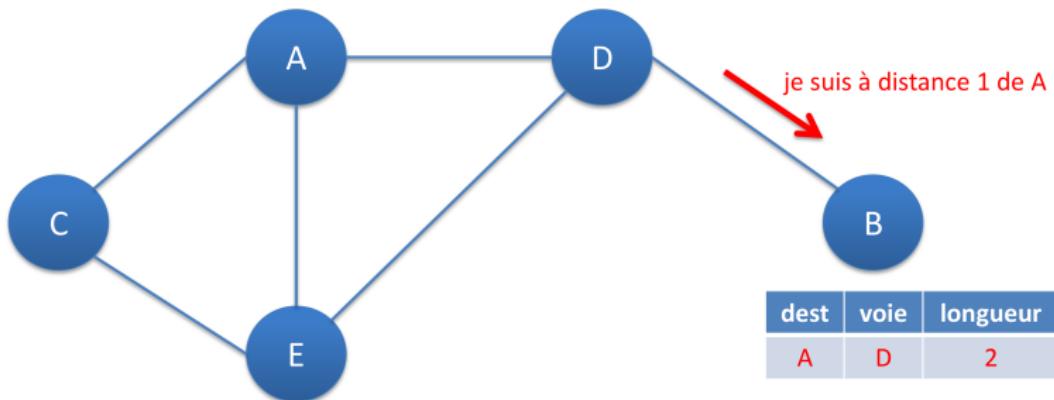
Exemple de calcul de table de routage (2/4)



Exemple de calcul de table de routage (3/4)



Exemple de calcul de table de routage (4/4)



Couche 4 : transport – TCP (Transport Control Protocol)

TCP :

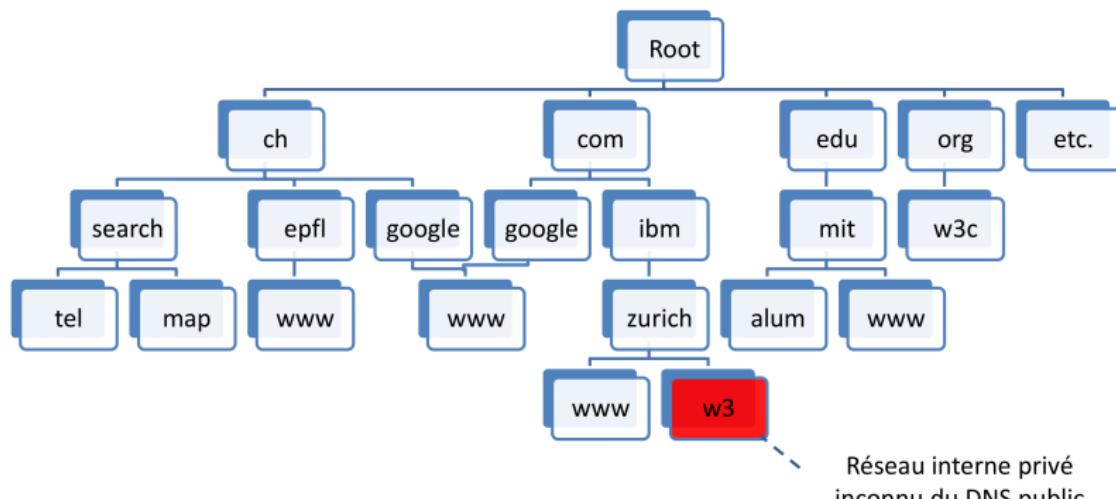
- ▶ protocole de programme à programme (« processus »)
- ▶ flux d'octets fiable :
 - ▶ Adresses des partenaires
 - ▶ Nombre et volume des messages envoyés et reçus
 - ▶ Réordonnancement et réassemblage des messages
 - ▶ Détection d'erreurs et retransmissions

SSL (Secure Session Layer) / TLS (Transport Layer Security) :
une version de TCP sécurisée *cryptographiquement* (v. leçon 14)

Couche 5 : p.ex. DNS (Domain Name System)

DNS traduit les noms en adresses, p.ex. www.epfl.ch en 128.178.50.12 (adresse IPv4) ou 2001:620:618:1a6:1:80b2:a60a:2 (adresse IPv6)

L'assignation de noms est **hiérarchique** mais également totalement **décentralisée**



Couche 5 : p.ex. le Web (HTTP)

HTTP (Hyper-Text Transfer Protocol)

Permet de manipuler des « ressources » au moyen de 8 messages différents dont 4 principaux :

- ▶ POST : crée - ou ajoute une information à - une ressource
- ▶ PUT : crée ou met à jour une ressource
- ▶ GET : lit et renvoie le contenu d'une ressource
- ▶ DELETE : élimine une ressource

Ces ressources sont désignées par des URI (Universal Resource Identifier)

`http:// hôte [: port] / [chemin-arborescent [? requête]]`

Le contenu des messages est exprimé en format HTML (Hyper-Text Markup Language)

HTTPS indique l'usage de HTTP sur SSL (Secure Session Layer) / TLS (Transport Layer Security) versions sécurisées cryptographiquement (v. prochaine leçon)

Résumé

- ▶ Architecture « de Von Neumann »
est une abstraction : la réalité est bien plus complexe
 - ☞ contraintes technologiques « opposées » (capacité/vitesse)
- ▶ Stockage / Réseaux : 2 facettes (espace / temps) d'un même problème
- ▶ Besoin de structuration de l'information,
des données (stockées/transmises)
 - ▶ **stockage** : les données peuvent être organisées logiquement de différentes façons : séquentielle, hiérarchique, relationnelle, ...
Le choix dépend des besoins (quel accès à quelle information ?)
 - ▶ **réseaux** : modèles en couches
- ▶ 3 besoins : identifier, localiser et accéder à (l'information)
et 3 moyens : noms, adresses, routes
- ▶ Identifiants : locaux / globaux, temporaires / permanents
- ▶ Un exemple concret : le routage IP (plus court chemin, distribué)